

Simulado estilo ENADE

Banco de Dados + Análise de Dados Aplicada à Computação

20 questões de múltipla escolha · CC e SI · 2026/2

Prof. M.Sc. Howard Cruz Roatti

Como usar

- **20 questões** no formato do ENADE (situação-problema → comando → 5 alternativas **A–E**, uma correta).
- **10 de Banco de Dados** (Q1–Q10) e **10 de Análise de Dados** (Q11–Q20).
- Tente responder **antes** de avançar para o slide de **gabarito comentado**.
- Nível cognitivo de **aplicar/analisar** — como o ENADE cobra (Resolução CNE/CES nº 5/2016; edições 2023 e 2026).

 Bom para simulado, revisão e para treinar o estilo de item do INEP.

Parte I — Banco de Dados

Q1 a Q10

Q1 — Álgebra relacional

Considere `Aluno(Matricula, Nome, IdCurso)` e `Curso(IdCurso, NomeCurso)`. Deseja-se obter **apenas os nomes** dos alunos matriculados no curso "**Sistemas de Informação**". Assinale a expressão correta.

- a) $\pi_{\text{Nome}}(\text{Aluno} \bowtie \text{Curso})$
- b) $\sigma_{\text{Nome}}(\pi_{\text{NomeCurso}}='Sistemas de Informação'(\text{Aluno} \bowtie \text{Curso}))$
- c) $\pi_{\text{Nome}}(\sigma_{\text{NomeCurso}}='Sistemas de Informação'(\text{Aluno} \bowtie \text{Curso}))$
- d) $\pi_{\text{NomeCurso}}(\sigma_{\text{Nome}}='Sistemas de Informação'(\text{Aluno} \bowtie \text{Curso}))$
- e) $\sigma_{\text{NomeCurso}}='Sistemas de Informação'(\text{Aluno} \bowtie \text{Curso})$

Q1 — Gabarito: c)

$\pi_{\text{Nome}}(\sigma_{\text{NomeCurso}='...'}(\text{Aluno} \bowtie \text{Curso}))$

- σ (seleção) filtra **linhas**; π (projeção) escolhe **colunas** (aqui, só Nome); a junção casa as chaves.
- Sem seleção (a) traz todos; papéis σ/π trocados (b); atributo errado (d); e **sem projeção** (e) devolve a tupla inteira — não "apenas os nomes".

Q2 — SQL com junção e agregação

Cliente(id, nome) · Pedido(id, id_cliente) · Item(id_pedido, qtd, valor). Quer-se o **nome** dos clientes cujo **valor total comprado** ($\sum$ qtd*valor) **ultrapassa 1000**.

- a) ... JOIN ... WHERE SUM(i.qtd*i.valor) > 1000 GROUP BY c.nome
- b) ... JOIN Pedido ... JOIN Item ... GROUP BY c.nome HAVING SUM(i.qtd*i.valor) > 1000
- c) ... JOIN ... GROUP BY c.nome HAVING i.qtd*i.valor > 1000
- d) SELECT c.nome FROM Cliente c WHERE SUM(c.valor) > 1000
- e) ... JOIN ... HAVING SUM(i.qtd*i.valor) > 1000 (sem GROUP BY)

Q2 — Gabarito: b)

```
GROUP BY c.nome HAVING SUM(i.qtd*i.valor) > 1000
```

- O filtro incide sobre um **agregado por grupo** → exige `GROUP BY` + **HAVING** (não `WHERE`, que filtra linhas **antes** de agrupar).
- (a) usa `SUM` no `WHERE`; (c) usa coluna não agregada no `HAVING`; (d) ignora as junções; (e) usa `HAVING` sem `GROUP BY`.

Q3 — Normalização

R(Aluno, Disciplina, Professor) tem **chave primária composta** (Aluno, Disciplina) e a dependência funcional **Disciplina → Professor**. Qual forma normal é **violada** e por quê?

- a) 1FN, por conter atributo **multivalorado**.
- b) 3FN, por dependência **transitiva** entre atributos não-chave.
- c) Nenhuma; a relação já está em 3FN.
- d) 2FN, pois Professor depende **parcialmente** da chave (só de Disciplina).
- e) Apenas a BCNF; a relação está em 3FN.

Q3 — Gabarito: d)

Viola a **2ª Forma Normal**.

- A chave é composta (Aluno, Disciplina); Disciplina → Professor faz Professor depender de **parte** da chave → **dependência parcial** → fere a **2FN**.
- Não é transitiva (seria 3FN) nem atomicidade (1FN). **Solução:** decompor em Turma(Disciplina, Professor) e Matricula(Aluno, Disciplina).

Q4 — Mapeamento de generalização

Pessoa (supertipo) especializa-se em **PessoaFisica** (CPF) e **PessoaJuridica** (CNPJ), especialização **total e disjunta**. Deseja-se um mapeamento relacional que **evite colunas nulas** e respeite a exclusividade.

- a) Uma tabela por subtipo (**PessoaFisica**, **PessoaJuridica**), cada uma com os atributos comuns de **Pessoa**; sem tabela do supertipo.
- b) Uma única tabela **Pessoa** com todas as colunas (CPF e CNPJ), a maioria nula em cada linha.
- c) **Pessoa** + subtabelas por FK, permitindo uma pessoa ser física e jurídica.
- d) Uma tabela **Pessoa** e listas de CPF/CNPJ separadas por vírgula.
- e) Substituir a generalização por um relacionamento M:N entre CPF e CNPJ.

Q4 — Gabarito: a)

Uma tabela por subtipo (para especialização **total e disjunta**).

- Como toda pessoa é **exatamente um** subtipo, tabelas por subtipo **eliminam os nulos** e preservam a disjunção.
- (b) gera muitas colunas **nulas**; (c) permitiria **sobreposição** (viola a exclusividade); (d) fere a 1FN; (e) descaracteriza a generalização.

Q5 — Isolamento de transações

Em **T1** lê-se o saldo de uma conta; em seguida **T2** **atualiza e confirma (commit)** esse saldo; ao **ler novamente** o mesmo registro, **T1** obtém um **valor diferente**. Qual anomalia ocorreu e qual nível de isolamento a evita?

- a) **Leitura suja** (dirty read); evitada por **READ COMMITTED**.
- b) **Leitura fantasma** (phantom); evitada por **READ UNCOMMITTED**.
- c) **Perda de atualização**; evitada por **READ UNCOMMITTED**.
- d) Nenhuma anomalia; o comportamento é sempre correto.
- e) **Leitura não repetível**; evitada a partir de **REPEATABLE READ**.

Q5 — Gabarito: e)

Leitura não repetível (non-repeatable read).

- T1 lê **duas vezes** e obtém valores diferentes por um **update confirmado** por T2 no intervalo → evitada a partir de **REPEATABLE READ**.
- **Dirty read** = ler dado **não confirmado**; **phantom** = surgem **novas linhas**; **lost update** = duas escritas se sobrepõem.

Q6 — Concorrência e bloqueios

Com bloqueio de duas fases (2PL): T1 bloqueia A e T2 bloqueia B; então T1 solicita B e T2 solicita A, cada uma aguardando a outra. Assinale a opção correta.

- a) O 2PL **garante** que deadlocks nunca ocorram.
- b) As duas transações concluem sem qualquer espera.
- c) Ocorre **deadlock** (espera circular); o SGBD detecta, escolhe uma **vítima** e faz **rollback**.
- d) Há **starvation** permanente que o SGBD não consegue tratar.
- e) O fenômeno observado é uma **leitura fantasma**.

Q6 — Gabarito: c)

Deadlock (espera circular).

- O 2PL garante **serialização**, mas **não previne deadlock**. O SGBD mantém um **grafo de espera**, detecta o ciclo, **aborta uma vítima** e faz **rollback** (a outra prossegue).
- Starvation é evitável por escalonamento; não há leitura de dados novos (phantom).

Q7 — Recuperação com log (WAL)

Após uma **falha do sistema**: T1 executou `commit` **antes** da falha (mas as alterações podem não ter ido ao disco); T2 estava **ativa** (sem `commit`). Que ações a recuperação aplica?

- a) **UNDO** em T1 e **REDO** em T2.
- b) **REDO** em T1 (refaz, pois confirmou) e **UNDO** em T2 (desfaz, pois não confirmou).
- c) **REDO** em ambas.
- d) **UNDO** em ambas.
- e) Nenhuma ação; o `commit` de T1 dispensa recuperação.

Q7 — Gabarito: b)

REDO em T1, UNDO em T2.

- Pelo **write-ahead logging**: transações **confirmadas** não persistidas sofrem **REDO**; transações **não confirmadas** sofrem **UNDO** (garante **atomicidade**).
- O **checkpoint** limita quão atrás no log o REDO precisa começar.

Q8 — Uso de índices

Índices aceleram consultas, mas têm custo de escrita/espço. Em qual situação a criação de um índice **tende a NÃO melhorar** o desempenho?

- a) Coluna `cpf` **única** usada em `WHERE cpf = ...`.
- b) **Chave estrangeira** usada com frequência em `JOIN`.
- c) Coluna de data usada em faixas (`BETWEEN`).
- d) Coluna de **baixa seletividade** (poucos valores distintos, ex.: um booleano) usada em filtro que retorna **metade** das linhas.
- e) Coluna usada com frequência em `ORDER BY`.

Q8 — Gabarito: d)

Coluna de **baixa seletividade**.

- Índice compensa quando a busca é **seletiva** (retorna poucas linhas). Se o filtro devolve grande parte da tabela, o otimizador prefere **varredura completa** — e o índice ainda **onera** escrita e espaço.
- Igualdade única, FKs em junções, faixas e ordenação (a, b, c, e) são casos em que o índice **ajuda**.

Q9 — NoSQL e Teorema CAP

Um carrinho de compras **distribuído globalmente** precisa continuar **disponível e aceitando escritas** mesmo durante **partições de rede**, tolerando inconsistência **temporária**. Qual escolha é adequada?

- a) Sistema **AP** (disponibilidade + tolerância a partição) com **consistência eventual** — ex.: banco de documentos/chave-valor distribuído.
- b) Sistema **CA** que garante **as três** propriedades simultaneamente.
- c) Banco relacional com **bloqueio global síncrono** entre todos os nós.
- d) Sistema **CP** que **recusa escritas** durante a partição.
- e) Indiferente: o Teorema CAP não se aplica a bancos NoSQL.

Q9 — Gabarito: a)

AP + consistência eventual (modelo **BASE**).

- Pelo **CAP**, sob **partição** escolhe-se **C ou A**. Como o carrinho precisa **aceitar escritas e permanecer disponível**, opta-se por **AP**, reconciliando depois (consistência **eventual**).
- (b) as três ao mesmo tempo é **impossível** sob partição; (d) CP recusaria escritas; (c) não escala globalmente.

Q10 — Arquitetura ANSI-SPARC

Uma equipe adiciona **índices** e muda a **organização física** de armazenamento de uma tabela, **sem alterar** os programas de aplicação nem o esquema conceitual. Esse cenário ilustra a:

- a) **Independência lógica de dados.**
- b) Ausência de independência de dados.
- c) Independência de **domínio**.
- d) Independência **referencial**.
- e) **Independência física de dados.**

Q10 — Gabarito: e)

Independência física de dados.

- Nos **três níveis (externo, conceitual, interno)**, mudar o **nível interno/físico** (índices, armazenamento) **sem afetar** o conceitual/aplicações é a **independência física**.
- A **independência lógica** seria mudar o **esquema conceitual** sem afetar as **views/aplicações** — não é o caso aqui.

Parte II — Análise de Dados

Q11 a Q20

Q11 — Medidas de tendência central

Uma amostra de salários (R\$) é: **2000, 2200, 2500, 2800, 50000**. Deseja-se descrever o valor **típico** do conjunto. Assinale a opção correta.

- a) A **média** é sempre a melhor medida de tendência central.
- b) A **mediana** (2500) representa melhor o típico, pois é **robusta a outliers**, enquanto a **média** (~11 900) é distorcida pelo valor extremo.
- c) A **moda** é a única medida válida para dados numéricos.
- d) O outlier (50000) **não afeta** a média.
- e) Média e mediana são **sempre iguais**.

Q11 — Gabarito: b)

A **mediana** é mais representativa aqui.

- A **média** é **sensível a outliers**; um único valor extremo a puxa para ~11 900, longe do "típico".
- A **mediana** (valor central) é **robusta**. Em distribuições **assimétricas**, representa melhor a tendência central.

Q12 — Medidas de dispersão

Dois conjuntos têm a **mesma média**, mas um tem valores muito mais **espalhados** em torno dela. Assinale a opção correta sobre desvio-padrão e IQR.

- a) Desvio-padrão e IQR **não têm relação** com dispersão.
- b) O IQR é **sensível a outliers**, por isso deve ser evitado.
- c) Conjuntos de mesma média têm **sempre** o mesmo desvio-padrão.
- d) O conjunto mais **disperso** tem **maior desvio-padrão**; o **IQR** ($Q3 - Q1$) mede os **50% centrais** e é **robusto a outliers**.
- e) O desvio-padrão pode ser **negativo**.

Q12 — Gabarito: d)

Maior espalhamento → **maior desvio-padrão**.

- O **desvio-padrão** quantifica a dispersão **em torno da média**; mesma média **não** implica mesma dispersão.
- O **IQR** = $Q3 - Q1$ resume os **50% centrais** e é **robusto a outliers** (base do boxplot). O desvio-padrão nunca é negativo.

Q13 — Amostragem e TLC

Estima-se a média de uma população a partir de **médias amostrais** de tamanho n . Assinale a opção correta.

- a) Pelo **Teorema Central do Limite**, a distribuição das médias amostrais tende à **normal** conforme n cresce, e o **erro-padrão** ($\sigma/\sqrt{n}$) **diminui** com n .
- b) O TLC exige que a **população** seja normal.
- c) O erro-padrão **aumenta** com o tamanho da amostra.
- d) A distribuição amostral da média é sempre **uniforme**.
- e) Aumentar n **não altera** a precisão da estimativa.

Q13 — Gabarito: a)

TLC + erro-padrão $\propto 1/\sqrt{n}$.

- O **TLC** vale para n grande **independentemente** da forma da população; a distribuição das médias aproxima-se da **normal**.
- O **erro-padrão** ($\sigma/\sqrt{n}$) **cai** com n → estimativas mais **precisas** com amostras maiores.

Q14 — Teste de hipótese

Em um teste com significância $\alpha = 0,05$, obtém-se **p-valor = 0,03**. Assinale a decisão e a interpretação corretas.

- a) O p-valor é a **probabilidade de H_0 ser verdadeira**.
- b) Como $p < \alpha$, **aceita-se H_0** .
- c) Como **$p (0,03) < \alpha (0,05)$, rejeita-se H_0** ; o p-valor é a probabilidade de obter resultado **tão ou mais extremo** que o observado, **supondo H_0 verdadeira**.
- d) Rejeitar H_0 sendo ela verdadeira é **erro tipo II**.
- e) Um p-valor pequeno **prova** H_1 com certeza.

Q14 — Gabarito: c)

$p < \alpha \Rightarrow$ rejeita-se H_0 .

- O **p-valor** mede quão extremos são os dados **sob H_0** — **não** é $P(H_0 \text{ verdadeira})$ nem prova de H_1 .
- Rejeitar H_0 verdadeira é **erro tipo I** (probabilidade = α); **não** rejeitar H_0 falsa é **erro tipo II**.

Q15 — Regressão e correlação

Ajusta-se `vendas ~ investimento_em_anúncios` por regressão linear: coeficiente angular **positivo** e $R^2 = 0,64$. Assinale a interpretação correta.

- a) O $R^2 = 0,64$ **prova** que anúncios **causam** vendas.
- b) Coeficiente angular positivo indica **correlação negativa**.
- c) O R^2 mede a **inclinação** da reta.
- d) Correlação de 0,64 significa **64% de acurácia** de classificação.
- e) O $R^2 = 0,64$ indica que **64% da variabilidade** das vendas é explicada pelo modelo; **correlação alta não implica causalidade**.

Q15 — Gabarito: e)

R^2 = proporção da variância **explicada**.

- $R^2 = 0,64 \rightarrow$ o modelo explica **64%** da variabilidade de vendas ; o restante fica com outros fatores/erro.
- **Correlação/regressão $\neq$ causalidade** (variáveis de confusão). O coeficiente **angular** ($\neq R^2$) dá a variação de y por unidade de x .

Q16 — Sobreajuste

Um modelo apresenta **erro muito baixo no treino** e **erro alto no teste**. Assinale o diagnóstico e a mitigação corretos.

- a) **Underfitting**; a solução é **aumentar** a complexidade.
- b) **Overfitting**: o modelo memorizou o treino (**baixo viés, alta variância**) e não **generaliza**; mitigar com mais dados, **regularização**, menor complexidade e **validação cruzada**.
- c) O modelo está **ideal**, pois errou pouco no treino.
- d) **Vazamento de dados** garante boa generalização.
- e) Alta acurácia no **treino** garante alta no **teste**.

Q16 — Gabarito: b)

Overfitting (sobreajuste).

- O **gap** entre bom desempenho no **treino** e ruim no **teste** é a assinatura do sobreajuste (**alta variância**).
- Mitigações: **mais dados**, **regularização**, **reduzir complexidade**, **validação cruzada** — o **trade-off viés–variância** em ação.

Q17 — Métricas em dados desbalanceados

Em detecção de fraude, **99% das transações são legítimas** e 1% são fraude. Um classificador que **prevê sempre "legítima"** atinge **99% de acurácia**. Assinale a opção correta.

- a) A **acurácia** é sempre a melhor métrica.
- b) A **revocação** mede a proporção de **negativos** corretos.
- c) 99% de acurácia significa **boa detecção** de fraudes.
- d) A **acurácia é enganosa** em dados **desbalanceados** (o classificador trivial já atinge 99%); **precisão, revocação e F1** (ou AUC) avaliam melhor a **classe minoritária**.
- e) O **F1** ignora os **falsos negativos**.

Q17 — Gabarito: d)

Acurácia **engana** em classes desbalanceadas.

- O classificador "sempre legítima" tem 99% de acurácia e **revocação 0** para fraude — inútil.
- **Revocação** = $TP/(TP+FN)$ (fraudes capturadas); **precisão** = $TP/(TP+FP)$; **F1** = média harmônica das duas. São essas (ou a **AUC**) que revelam o desempenho na **classe rara**.

Q18 — Tipo de aprendizado

Uma empresa quer **segmentar clientes** em grupos de comportamento semelhante, **sem rótulos** predefinidos. Assinale a abordagem adequada.

- a) **Aprendizado não supervisionado** (clusterização, ex.: **k-means**), que agrupa por **similaridade** sem rótulos.
- b) **Aprendizado supervisionado** (classificação), pois há rótulos definidos.
- c) **Regressão linear**, para prever o grupo.
- d) **k-means é supervisionado** e exige a variável-alvo.
- e) É preciso **rotular manualmente** todos os clientes antes de qualquer análise.

Q18 — Gabarito: a)

Não supervisionado (clusterização).

- Sem **variável-alvo (rótulo)**, usa-se aprendizado **não supervisionado**; o **k-means** agrupa por **distância/similaridade**.
- O **supervisionado** (classificação/regressão) exige **y rotulado** — que não existe aqui.

Q19 — pandas: agregação por grupo

Considere o código:

```
import pandas as pd
df = pd.DataFrame({'regiao': ['S', 'N', 'S', 'N'],
                   'venda': [10, 20, 30, 40]})
r = df.groupby('regiao')['venda'].mean()
```

O que `r` contém?

- a) Uma Series com a **soma**: $S = 40$, $N = 60$.
- b) Um DataFrame com **todas** as linhas originais.
- c) Uma **Series** com a média por região: **$S = 20.0$** e **$N = 30.0$** .
- d) **Erro**, pois `groupby` não aceita coluna categórica.
- e) O **primeiro** valor de cada grupo: $S = 10$, $N = 20$.

Q19 — Gabarito: c)

Series com a **média por grupo**.

- `groupby('regiao')['venda'].mean()` agrupa por `regiao` e calcula a **média** em cada grupo:
 $S = (10+30)/2 = 20.0$; $N = (20+40)/2 = 30.0$.
- O resultado é uma **Series** indexada pela `regiao` (não a soma nem o primeiro valor).

Q20 — Vazamento de dados

Ao preparar um modelo, escalona-se (normaliza) **todo o conjunto** usando média/desvio calculados sobre **todos os dados** e **só então** divide-se em treino e teste. Assinale a opção correta.

- a) Não há problema; escalonar **antes** de dividir é a prática recomendada.
- b) O correto é **ajustar no teste** e aplicar no treino.
- c) **Vazamento de dados melhora** a generalização.
- d) Escalonamento **nunca** afeta a avaliação do modelo.
- e) Há **vazamento de dados**: o *scaler* usou estatísticas do **teste**; o correto é **ajustar (fit) só no treino** e **aplicar (transform)** no teste — idealmente via **Pipeline**.

Q20 — Gabarito: e)

Data leakage (vazamento de dados).

- Calcular estatísticas de pré-processamento sobre **treino + teste** deixa informação do teste "vazar" e **infla** as métricas.
- Regra: **fit** só no **treino**, **transform** no teste. Um **Pipeline** + **train_test_split** (estratificado em classificação) garante isso.

Fim do simulado

20 questões · Banco de Dados + Análise de Dados

Gabarito: 1c 2b 3d 4a 5e 6c 7b 8d 9a 10e · 11b 12d 13a 14c 15e 16b 17d 18a 19c 20e